INVESTMENT BRIEF

生物医药 Benchmark 版图

从模型榜单走向研发生产力基础设施

核心判断：真正有投资价值的，不是单个 benchmark 的榜单排名，而是能够持续连接稀缺数据、专家判断、真实工作流和企业验收 的评测基础设施。

45	39	12	A-E
已纳入 benchmark	归一化机构实体	一级子领域	价值证据等级

投资人应关注的三条主线

- 数据壁垒：临床病例、专家标注、实验测量、真实 notebook 和工具执行轨迹，比普通公开问答更难复制。
- 工作流嵌入：蛋白设计、药物发现、临床 Agent、生物科研 Agent 的结果可以直接影响研发排序和人力配置。
- 评测基础设施：当模型从论文走向企业部署，持续、可审计、可复现的 benchmark 会从研究工具升级为验收和合规工具。

但目前公开资料几乎没有 benchmark 级别的采购金额、付费客户数或授权收入披露。因此，本报告把“已实现商业价值”和“潜在经济价值”严格分开。

本报告基于项目内 45 个 benchmark registry、组织归属、子领域映射和经济价值证据表；不构成市场规模、收入或估值预测。

01 / ORGANIZATION LANDSCAPE

谁在定义生物医药 AI 的评测标准？

当前样本显示，benchmark 的供给并不只来自 AI 大厂。高校实验室、研究平台、挑战联盟和开放社区共同构成了标准层。

组织类型	按 benchmark 归属计数	投资含义
高校/大学实验室	13	专家数据和方法创新，商业化通常间接
AI公司/产业研究实验室	11	模型发布、企业验收和数据服务的潜在入口
社区/开放生态	8	标准扩散和开发者生态，收入未必直接
挑战联盟/研究联盟	4	长期盲测、行业标准和稀缺评价数据
研究机构/平台	3	连接数据、算力、榜单和科研工作流

机构地图中的重点节点

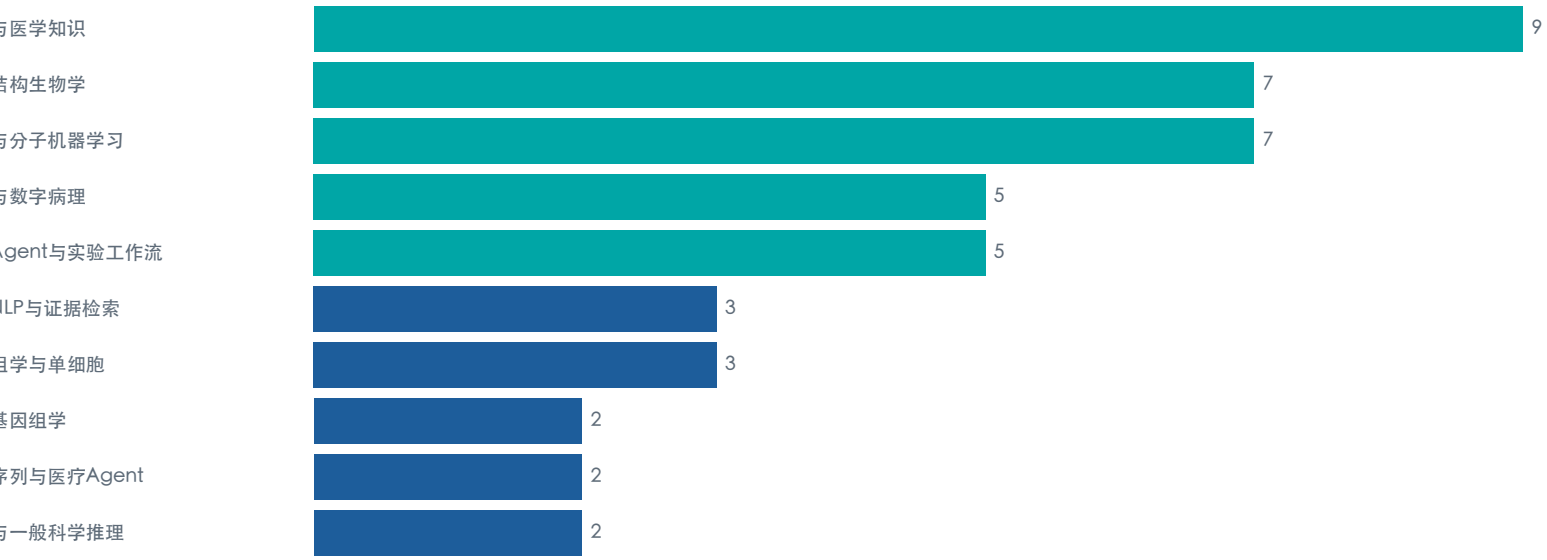
机构/平台群	代表 benchmark	可观察的价值位置
OpenAI / Anthropic / Microsoft	HealthBench; LifeSciBench; BioMysteryBench; HealthAgentBench	安全、科研 Agent、临床工作流验收
ByteDance Seed / Research	ProteinBench; PXMeter; PXDesignBench; SuperGPQA	蛋白基础模型、结构和设计能力评测
清华 C3I / 上海 AI Lab / OpenCompass	MedXpertQA; MedBench	中文专家医学、多模态和模型榜单
FutureHouse / xbench / Phylo	LAB-Bench; BixBench; BiomniBench-DA	科研工具调用、真实数据分析、Agent 生产力
CASP / CAMEO / BioASQ / DeepChem	结构预测、检索、分子机器学习	长期标准、挑战赛和社区基础设施

判断：机构数量不是壁垒指标。更值得关注的是，机构是否掌握不可替代的数据、能否持续更新评测，以及是否处于企业采购或模型发布流程的关键节点。

02 / SUBCATEGORY MAP

从 45 个 benchmark 看，价值集中在四条主赛道

子领域采用多标签体系；一个 benchmark 可以同时服务模型评测、药物研发和临床工作流。下面的数量是 benchmark 数，不是题目数量。



四条高优先级赛道

赛道	代表 benchmark	为什么值得看
蛋白质与结构生物学	PXDesignBench; ProteinGym; CASP; CAMEO	实验筛选成本高，结果可直接影响候选蛋白排序
药物发现与分子机器学习	TDC; LIT-PCBA; GuacaMol; PoseBusters	买方明确，研发流程长，数据和验证成本高
生物科研 Agent	LAB-Bench; BixBench; BiomniBench-DA	评测结果可转化为科研时间节省和工具调用成功率
临床 Agent 与医学安全	HealthBench; HealthAgentBench; MedXpertQA	进入医疗场景必须有安全、专家和流程级验收

其他重要方向包括遗传学与基因组学、功能基因组学与单细胞、医学影像与数字病理、生物医学 NLP 以及科学复现。它们更适合按具体买方和工作流拆分，而不是只按学术术语排序。

03 / VALUE CHAIN

Benchmark 的经济价值，取决于它离决策有多近

投资判断应从“题目难不难”转向“评测结果是否改变高成本决策”。

价值链位置	典型买方	被影响的决策	更可能的商业形态
科研生产力	药企、CRO、科研软件公司	文献筛选、数据分析、实验计划	按席位 / 按量 API / 企业部署
生物技术研发	药企、抗体/酶工程公司	候选蛋白、靶点、化合物排序	数据授权 / 平台订阅 / 合作研发
临床决策支持	医院、医疗器械和软件厂商	诊断、报告、风险分层	软件集成 / 验收服务 / 合规评测
模型与安全验收	模型厂商、云平台、企业采购方	发布门槛、模型卡、红队和持续监测	评测服务 / 私有测试集 / 认证
标准与生态基础设施	高校、挑战联盟、平台	行业比较、人才和科研复现	间接价值、赞助、平台和数据服务

最强的商业模式通常不是出售一个公开榜单，而是围绕 benchmark 形成闭环：

- 稀缺数据集或私有测试集；
- 企业专属评测和模型验收；
- 工作流级 Agent 评测与持续监测；
- 实验/临床结果与模型表现的回溯验证；
- 面向药企、医院或模型厂商的年度订阅。

可投资的不是“分数”，而是 分数背后的数据、流程和验证关系。

当前最重要的结论：潜在价值高，公开交易证据少

现有评估中，37/45 个 benchmark 被标为 high 或 medium-high economic relevance；但公开资料尚未披露 benchmark 级别的采购金额、客户数量或授权收入。

证据级别	含义	当前解读
A	公开合同、采购、授权或价格	当前 registry 未记录可核验的 benchmark 级金额
B	官方产品集成、企业服务或正式合作	需要进一步做公司/产品级核验
C	长期排行榜、标准、多机构采用	多个经典 benchmark 已具备标准层价值
D	基于数据稀缺、决策影响和替代成本推断	当前高潜力方向的主要证据类型
E	证据不足	仅作为候选方向，不进入核心投资结论

潜在价值优先级 Top 8

Benchmark	子领域	潜在价值分数	证据等级	主要买方
pxdesignbench	unknown	4.8	D	抗体、酶工程、合成生物学
tdc	unknown	4.8	D	药企、CRO、药物研发平台
protein_gym	unknown	4.8	D	蛋白工程、酶工程、抗体研发
lab_bench	unknown	4.7	D	药企研发、科研软件、实验自动化
bixbench	notebook	4.7	D	药企研发、科研软件、算力平台
healthagentbench	agent	4.7	D	医院工作流、医疗软件、模型验收
biomnibench_da	agent	4.7	D	药企研发、CRO、科研平台
sequential_diagnosis	unknown	4.7	D	医院辅助决策、医疗 Agent

解释：这些分数是项目内部的潜在价值优先级，不是收入预测。没有 A/B 证据的项目，下一步应优先验证客户、采购流程和实际成本节省。

四个可验证的投资假设

假设	可验证指标	主要风险
1. 生物科研 Agent 会从演示走向工作流采购	真实 notebook 任务完成率、工具调用成功率、科研时间节省、企业续费	任务过于合成；评测分数与真实实验结果脱节
2. 蛋白设计与药物发现评测会连接实验预算	候选命中率、实验轮次减少、lead 优化周期、药企项目采用	公开 benchmark 与企业私有数据分布偏移；湿实验验证慢
3. 医疗模型需要独立的安全和流程验收层	专家一致性、严重错误率、拒答质量、医院/企业验收项目	监管、隐私和责任边界；单一榜单不能代表临床有效性
4. 私有测试集和持续监测比公开榜单更容易商业化	私有数据订阅、年度复测、模型版本监测、企业续约	数据合规、标注成本和客户集中度

不建议的投资叙事

- 只用论文引用数证明商业价值；
- 把 benchmark 的公开使用量等同于付费客户数；
- 把模型在考试题上的高分等同于临床可用；
- 把一个公开数据集的题量直接等同于数据资产价值。

真正需要尽调的三个问题

- 谁在为评测结果付费，而不是谁在论文里引用？
- 评测是否改变了研发、临床或模型发布决策？
- 数据和专家标注是否能持续更新，形成复购而非一次性项目？

06 / DUE DILIGENCE ROADMAP

下一步：从 landscape 走向可投资标的

建议用 90 天完成第一轮验证，不先追求覆盖所有 benchmark，而先验证三个高价值方向。

阶段	动作	交付物
0-30 天：归一化	核验机构实体、官方版本、许可证、题目/任务数量和排行榜	机构实体表、版本表、来源证据
31-60 天：需求验证	访谈药企/CRO/医院/模型厂商，确认买方、验收流程和替代成本	买方地图、用例清单、采购触发点
61-90 天：价值验证	对蛋白设计、药物发现 Agent、医疗安全做小规模复测和成本对照	私有评测样例、时间节省、错误成本和续费假设

建议优先验证的三条路径

方向	第一批访谈对象	第一项硬指标
蛋白质设计 / 突变效应	抗体、酶工程、生物制药研发团队	实验筛选轮次或候选命中率
生物科研 Agent	药企计算生物、CRO、科研软件团队	一个完整工作流的人工小时节省
医疗安全 / 临床 Agent	医院、医疗软件、模型厂商	严重错误率、专家接受度和验收周期

结论

这个市场的投资机会不在“再做一个榜单”，而在于把公开 benchmark、私有数据、专家判断和真实研发/临床流程组合成可持续的评测产品。当前最有吸引力的方向具备高数据壁垒、高决策影响和明确买方，但仍需要从潜在价值走到 A/B 级商业证据。

数据来源：项目内 benchmark_registry.csv、benchmark_organization.csv、benchmark_assessment.csv、organization_entity.csv、benchmark_subcategory_mapping.csv、benchmark_economic_value_evidence.csv。金额、客户数和合同信息以公开披露为准；未披露不等于不存在。