GROUNDSIGNAL / 生物医药 Benchmark 专题研究

生物医药 AI 的评测价值，要落到具体工作流

生物方向的benchmark调查报告

从公开评测到科研任务、模型验收与产业需求

核心判断

公开 Benchmark 可以提供能力对照与研究入口。可持续的应用价值，来自把评测任务与真实决策、可复现证据、失败成本及重复使用需求连接起来。

本次研究范围	现有规模
Benchmark 登记记录	45 条；包含题库、数据集、工具、套件与挑战赛
机构实体记录	39 条；不同机构层级与社区标签尚待归一化
已覆盖主领域	10 类；另讨论 2 个待补的一级类别
交付重点	机构分类、10 类实用意义、潜在买方、出题方向及验证路径

研究日期：2026年10月13日

面向：生物医药 AI 投资与产业研究、Benchmark 产品规划、科研 Agent 评测与出题。

本报告参考用户提供的 AI for 集成电路报告的紧凑结构与表格表达，重新研究生物医药专题。

能力判断与商业判断需要不同证据

一、执行摘要

建议切入口

优先做能实际重跑、能检验科学错误、能嵌入明确工作流的窄域评测。对本项目而言，可先从单细胞与扰动分析、证据检索或科研数据分析工作流中选择一个，完成小规模参考解与独立评分。

当前版图的价值在于横向组织来源：45 条记录覆盖 10 类主领域，六张表把任务、机构和价值描述联系起来。但现有质量评分均是 provisional 初评，尚不能作为已完成的科学审计或市场估值依据。

实用意义应按决策拆分：知识与对话评测支持发布前筛查；预测与设计评测支持方法选择和实验前排序；多步 Agent 与复现评测支持工作流委托和回归验收。

市场线索已有，但需要区分口径。上海 AI Lab 在 2026-07-30 的官方更新中披露 MedBench 累计完成超过 31 万次评测，这是平台级采用信号，不是本项目收入，也不证明评测业务的合同金额。[R09]

建议的产品顺序是：公开窄域样例和研究报告 → 有明确客户问题的私有评测试点 → 模型与数据更新后的持续回归。客户、价格与复购需要实际试点验证，本报告不虚构市场规模或收费区间。

研究方法与统计范围

证据层	本次处理方式
仓库快照	使用 main 提交 ed60c7d 的六张 CSV 与专题文档；五张 Benchmark 表各 45 条，机构表 39 条。
官方核验	重点查阅代表项目的官方页面、仓库和论文入口；长尾归属保留现有登记状态，不宣称 45 项全部完成审计。
分析判断	各类别的买方、工作流价值与产品建议为本报告分析；实际增益应通过客户数据和配对试验验证。
缺失信息	缺失不记为零；初评分、商业假设与实际交易分别记录。引用访问日期为 2026-10-13。

现有经济价值表：C 级 22 条、D 级 23 条，A/B/E 级均为 0；45 条公开金额均为未披露。后续官方采用信号可用于更新证据记录，不能直接覆盖历史统计口径。

按角色看布局，不能只按品牌看“拥有多少题”

二、机构版图：公司、科研组织与产业团队

机构组	机构 / 团队	登记项目	角色与重点
国内 AI 公司及产业团队	ByteDance Research / Seed	ProteinBench、PXMeter、PXDesignBench、SuperGPQA	模型团队发布评测与工具；蛋白预测、设计和一般科学推理。[R18-R20,R28]
国际 AI 公司及研究团队	OpenAI	HealthBench、LifeSciBench、GeneBench、GeneBench-Pro	健康安全、研究工作流和计算生物学；应按任务和发布版本分别记录。[R01-R03]
国际 AI 公司及研究团队	Anthropic	BioMysteryBench	生物数据分析的客观结果评测；正式跑分需固定题集版本。[R04]
国际 AI 公司及研究团队	Microsoft	HealthAgentBench、Sequential Diagnosis Benchmark	分别为医疗 Agent 环境与逐步诊断；团队归属不能一概合并为同一实验室。[R05-R06]
国际 AI 公司及研究团队	Google Research	MultiMedQA	评测套件汇编者；组件数据集仍有各自创建和维护机构。[R07]
科研组织与联合团队	FutureHouse / 合作团队	LAB-Bench、BixBench	研究能力与开放式分析。BixBench 官方仓库署名 FutureHouse 与 ScienceMachine 合作。[R12-R13]
评测研究与产业团队	FreedomIntelligence、xbench 相关合作方、UniPat AI	CMB、BiomniBench-DA、PaperBenchX	中文医学、过程分析与科学复现；具体合作角色按论文和官方说明核验。[R10,R14,R27]
生物技术及开放生态	BenevolentAI、Molecular Sets 社区	GuacaMol、MOSES	登记表中的分子生成方向；企业起源不等于当前评测收费。

分类是本报告为阅读设计的分组，组间可能有合作交叉，不用于计算市场份额。FutureHouse、合作公司和开放社区不应被强行归为同一种商业主体。

机构核验中的三个修正

Google 是 MultiMedQA 套件的汇编者，组件仍有独立归属；BixBench 官方仓库写明 FutureHouse 与 ScienceMachine 合作，与现有 CSV 的 Edison Scientific 描述存在差异；Microsoft 的具体研究团队应以各项目作者与发布说明为准。[R05-R07,R13]

机构可能是创建者、维护者、托管方、数据提供方或采用方。合作关系和公司采用评测都不自动产生所有权；品牌归属也不等于评测质量。

按学校、实验室和治理角色分层

三、机构版图：高校、平台与挑战社区

机构组	机构 / 团队	登记项目	定位与核验重点
高校与研究机构联合	清华大学 / 上海 AI Lab；上海 AI Lab / OpenCompass	MedXpertQA；MedBench	前者是联合学术项目；后者是版本化中文医疗评测平台。[R08-R09]
高校实验室	Harvard Zitnik Lab	Therapeutics Data Commons	治疗相关任务平台；具体子任务的数据来源和许可需分别核验。[R24]
高校相关团队	Stanford AIMI、SNAP 及相关学术合作	CheXpert、GEARS、MedQA、FLIP/FLIP2	AIMI 与 SNAP 是不同团队；MedQA 与 FLIP 的完整归属需按论文复核。[R17]
高校与数据平台	MIT / PhysioNet / 临床合作方	MIMIC-CXR	数据创建、临床来源、托管与访问治理是不同角色。[R26]
高校与研究团队	Theis Lab；上海交通大学相关团队；AIIMS；CUHK AIM	scIB；MedMNIST；MedMCQA；CMExam	登记归属导航；未将所有来源逐项升级为已核验事实。[R16]
多机构学术合作	Marks Lab / OATML 及合作者	ProteinGym	实验突变与临床变异评测，应区分测量性质与任务版本。[R21]
挑战联盟与持续评测	BioASQ；CASP；CAMEO / SwissModel / SIB	BioASQ；CASP；CAMEO	周期挑战与持续评测，适合研究标准、盲测和新版本比较。[R11,R22-R23]
开放社区与挑战生态	Open Problems；DeepChem；国际病理合作社区	Open Problems、MoleculeNet、CAMELYON	提供社区方法比较和数据入口；托管平台与创建者不应混记。[R15]
尚需细化的归属	学术团队、结构/对接社区、国内医学社区	PubMedQA、LIT-PCBA、PoseBusters、DUD-E、CBLUE、GMAI-MMBench、MSDiagnosis	现有表包含笼统社区标签；应补全作者、单位和版本，不能直接统计成独立公司。[R25]

以上长尾项目的名称与归属来自现有登记表；仅有笼统“学术社区”描述的项目需要补论文作者与机构，不能据此归为某家公司。

为什么这些机构值得区分

高校实验室提供任务和方法研究；医院及数据平台提供数据与访问治理；挑战联盟提供盲测和长期比较。产业团队更容易把评测接到产品迭代，但使用价值仍需外部数据与独立验证。

用途 → 决策 → 验收 → 实际价值

四、各大类的实用意义 1/5

01 临床医学与医学知识 / 9 条登记

登记项目：MedQA-USMLE、MedMCQA、MultiMedQA、HealthBench、MedXpertQA、MedBench、CMB、CMExam、MSDiagnosis

为医疗模型建立知识、沟通和安全底线，帮助定位发布前需要人工复核的失败场景。

维度	实用意义与验证要求
实际工作	医疗问答、医学教育、患者沟通与诊疗信息辅助。考试题检验知识，开放式对话更适合检查澄清问题、表达不确定性和识别风险。
谁会使用	医疗模型团队、健康平台、医学教育产品和医院信息部门；这是潜在用户画像，不能据此认定已经采购。
关键决策	选择基础模型、决定哪些问题交给人工、检查版本升级是否增加危险回答；先按人群和场景分层，再看总体平均分。
怎样验收	知识题正确率之外，报告严重错误率、遗漏关键建议的比例、专家一致性与置信度校准。HealthBench 的医生量表提供开放式评分实例。[R01]
能形成的价值	把模型升级变成重复安全回归，减少专家逐次从零评审的工作；实际节省量须与人工流程配对测量。
能力边界	考试高分不能证明临床结局改善；医院部署还需要本地病例、流程验证和持续监测。MedBench 与 MedXpertQA 应明确版本及任务范围。[R08-R10]

02 生物医学 NLP 与证据检索 / 3 条登记

登记项目：PubMedQA、BioASQ、CBLUE

把检索和抽取结果变成能支持具体主张的证据，适合文献研究、知识库与研发情报工作。

维度	实用意义与验证要求
实际工作	检索论文、抽取疾病与药物关系、回答证据问题、为综述和研发判断整理引用。BioASQ 包含检索与问答挑战，可区分找不到证据和解释错误。[R11]
谁会使用	药企情报团队、医学知识服务、科研搜索产品和知识库维护者。
关键决策	选检索系统和模型、决定某条关系是否进入知识库、识别哪些结论需要进一步检索；更适合支撑证据工作流的局部决策。
怎样验收	联合检查检索召回、证据与主张的对应性、引用定位、答案忠实度、时间有效性和无法回答时的弃答行为。
能形成的价值	降低重复搜索与引用核对成本，形成可审计的知识更新服务；应测量每条有效证据成本和专家复核时间。
能力边界	摘要问答正确不等于完成系统综述，也不证明因果结论。要处理反证、重复研究、研究对象差异和失效证据。

用途 → 决策 → 验收 → 实际价值

四、各大类的实用意义 2/5

03 生物科研 Agent 与实验工作流 / 5 条登记

登记项目：LAB-Bench、BixBench、BioMysteryBench、LifeSciBench、BiomniBench-DA

判断 AI 能否完成可复现的研究辅助工作，并识别代码运行与科学分析之间的差距。

维度	实用意义与验证要求
实际工作	读取组学文件、检索数据库、编写分析脚本、执行工具、解释结果与形成可交接的研究材料。LAB-Bench 和 BixBench 分别提供基础研究能力与开放式分析入口。[R12-R13]
谁会使用	药企研发、计算生物学团队、科研软件与 Agent 平台。
关键决策	选择哪些分析环节可以委托 AI，确定需要专家介入的位置，比较模型与工具配置，而不是只比较聊天回答。
怎样验收	同时记录科学结果、关键假设、数据质控、干净环境重跑、错误恢复与成本。BioMysteryBench 的客观元数据任务可用于验证结果；过程评审需明确允许多种方法。[R04]
能形成的价值	减少分析准备和重复运行的时间，为真实工作流构建版本回归与专家失败库。LifeSciBench 覆盖更广泛研究任务。[R02]
能力边界	任务成功不代表自动完成新发现；不能奖励固定分析路径或文件数量。BiomniBench-DA 的过程评测可作方法参考，具体评分需核验。[R14]

04 遗传学与基因组学 / 2 条登记

登记项目：GeneBench、GeneBench-Pro

检验模型能否从复杂数据中提出合适的分析问题，并在混杂和不确定性下作出可支持的判断。

维度	实用意义与验证要求
实际工作	遗传关联、数量遗传学、组学统计与转化研究中的多阶段分析。GeneBench-Pro 强调数据探索、目标估计量和分析方案的修订。[R03]
谁会使用	基因组研究团队、药物靶点研究、遗传分析软件与计算生物学模型团队。
关键决策	数据是否支持当前问题、该采用哪个模型、是否需要修改目标估计量、结论是否足以进入后续验证。
怎样验收	检查样本与批次结构、模型假设、效应估计、置信区间、多重检验和敏感性分析；给统计上等价且科学合理的解法留空间。
能形成的价值	降低因混杂、样本依赖或统计错误导致的返工，为研究审查与分析验收提供可复用任务。
能力边界	这两项是计算研究评测，不能直接替代临床变异分级或遗传咨询认证。临床遗传解读需要独立的证据与患者场景评测。

用途 → 决策 → 验收 → 实际价值

四、各大类的实用意义 3/5

05 功能基因组学与单细胞 / 3 条登记

登记项目：Open Problems in Single-Cell Analysis、scIB、GEARS

为方法选择与扰动预测提供量化依据，适合虚拟细胞和靶点筛选的有限范围验证。

维度	实用意义与验证要求
实际工作	单细胞整合、批次校正、标签迁移与扰动后的表达预测。Open Problems 提供任务化比较，scIB 同时关注批次消除和生物信息保留。[R15-R16]
谁会使用	单细胞分析平台、功能基因组学团队、靶点研究与虚拟细胞模型研发者。
关键决策	选整合方法、判断哪些候选扰动值得进入实验、筛查模型是否在新基因或新组合上失效；GEARS 提供扰动预测入口。[R17]
怎样验收	以生物重复和条件为单位划分数据，比较无变化、均值和单扰动基线；报告差异基因、状态分布及组合扰动效应，而非只有整体相关性。
能形成的价值	帮助减少明显无效候选与错误分析路径，把模型定位为实验前排序的一层；需通过留出实验或前瞻实验测量筛选增益。
能力边界	一个细胞系的表达预测不能外推为患者药效；批次混合漂亮也可能抹除真实生物差异。随机划分和多数不变基因易掩盖问题。

06 蛋白质与结构生物学 / 7 条登记

登记项目：ProteinBench、PXMeter、PXDesignBench、ProteinGym、FLIP/FLIP2、CASP、CAMEO

分别检查结构、设计和突变效应，帮助决定模型及候选是否值得进入下一轮实验。

维度	实用意义与验证要求
实际工作	结构预测、复合物评估、骨架与序列设计、突变效应排序。ProteinBench 强调多指标，PXMeter 和 PXDesignBench 提供结构与设计评测工具。[R18-R20]
谁会使用	抗体、酶工程、蛋白药物研发和结构模型团队。
关键决策	选结构模型、筛除不合理设计、确定突变和候选的实验优先级。各子任务应独立比较，结构分数与功能分数不可直接合并。
怎样验收	结构误差、界面质量、物理合理性、序列多样性和实验功能分别报告；ProteinGym 用实验突变测量检查排序能力。[R21]
能形成的价值	用统一协议做模型选择和实验前过滤；CASP 盲测与 CAMEO 连续评估提示应采用时间留出和新目标检验。[R22-R23]
能力边界	预测置信度不是结合、活性或可开发性证据。候选要成为药物，还需表达、稳定性、选择性和适用实验条件的独立验证。

用途 → 决策 → 验收 → 实际价值

四、各大类的实用意义 4/5

07 药物发现与分子机器学习 / 7 条登记

登记项目：Therapeutics Data Commons、MoleculeNet、LIT-PCBA、PoseBusters、DUD-E、GuacaMol、MOSES

为分子筛选管线的具体一层提供证据，检查排序、性质预测和生成候选是否优于基础方法。

维度	实用意义与验证要求
实际工作	性质与 ADMET 预测、虚拟筛选、对接、分子生成和候选排序。TDC 将不同治疗相关任务组织为独立数据与评测组。[R24]
谁会使用	药企发现团队、CRO、化学信息学软件与分子模型研发者。
关键决策	采用哪种排序或过滤方法、把有限实验预算分给哪些候选、如何设置弃答或适用域。
怎样验收	使用骨架、靶点或时间留出；在固定实验预算下报告富集与命中，同时检查校准和物理合理性。PoseBusters 可识别不合理分子姿态。[R25]
能形成的价值	减少低质量候选进入昂贵实验的机会，形成项目级回归和私有测量评测；节省成本须扣除推理、复核与后续验证。
能力边界	对接合理不等于有活性，性质预测不等于体内药效，分子新颖不等于可合成。公开任务平均分不代表整条研发管线效率。

08 医学影像与数字病理 / 5 条登记

登记项目：GMAI-MMBench、MedMNIST、MIMIC-CXR、CheXpert、CAMELYON

评估影像分类、图文一致性与病理识别，为影像软件选型和本地部署验证提供依据。

维度	实用意义与验证要求
实际工作	胸片分类、图像与报告建模、病理切片识别及多模态问答。MIMIC-CXR 提供影像与放射报告，是一种临床数据入口。[R26]
谁会使用	医学影像模型团队、医院信息与放射部门、病理软件企业。
关键决策	选择适合目标设备、医院和病例分布的模型，决定哪些结果交由医生复核。小型标准化集适合工程初测，不能承担全部部署验收。
怎样验收	按患者与医院划分，检查关键病变灵敏度、特异度、校准、漏报和图文矛盾；采用设备变化与外部中心测试。
能形成的价值	形成医院或设备场景的持续回归，发现新模型的漏诊风险；用户收益需要观察真实复核时间和流程影响。
能力边界	离线分数不等于临床获益。MIMIC-CXR 有认证与数据使用要求；取得访问权限不自动授权公开再分发。[R26]

用途 → 决策 → 验收 → 实际价值

四、各大类的实用意义 5/5

09 临床时间序列与医疗 Agent / 2 条登记

登记项目：HealthAgentBench、Sequential Diagnosis Benchmark

评估模型如何主动获取信息、选择下一步行动，以及能否完成医疗数据工作流。

维度	实用意义与验证要求
实际工作	逐步诊断中的问询、检查选择与假设更新，以及医疗数据和工具环境中的多步任务。这两个项目应按具体任务区分，不能把全部任务都称为临床诊断。[R05-R06]
谁会使用	医疗 Agent 平台、医院数据团队、临床决策软件研发者。
关键决策	何时追问、何时停止检查、何时升级人工，哪些工具或数据操作可交给 AI。
怎样验收	结合最终结果、检查次数与成本、信息利用、时间泄漏、权限操作和安全升级；工具调用数量本身不是成功指标。
能形成的价值	为流程自动化建立失败诊断与回归集，比较同一预算下的策略；真实收益来自本地受控试点。
能力边界	案例交互和离线环境会简化医疗现实，不能把公开演示准确率当作临床准入结论；政策、病例和工具约束需本地化。

10 科学复现与一般科学推理 / 2 条登记

登记项目：PaperBenchX、SuperGPQA

分别测试专家知识推理和可执行证据复现，帮助判断模型能否完成科学软件与验证工作。

维度	实用意义与验证要求
实际工作	专家级问题求解，或将论文说明变成可重跑的代码、环境和结果。PaperBenchX 区分建模、执行和验证阶段。[R27]
谁会使用	科研 Agent 团队、科学软件、计算平台与研究机构。
关键决策	选择适合论文复现和工具操作的模型，定位失败来自科学建模、软件运行还是结果验证。
怎样验收	固定数据与环境后清理旧输出，再从头执行；数值容差与证据要求应围绕论文主张定义。报告完整成功与部分成功。
能形成的价值	减少复现中的工程返工，为科学计算平台提供版本回归与可审查失败样本。
能力边界	SuperGPQA 的知识分数与论文复现成功是不同能力；广义科学套件只有部分任务属生物医药，报告应单列对应子集。[R28]

分类方案有 12 类；当前登记覆盖 10 类

五、尚未作为主领域收录的两类

11 公共卫生与健康服务

实际意义：检验人群风险预测、资源分配、健康管理与干预评估，支持公共卫生机构和健康服务平台决定在哪里配置有限资源。现有临床知识题可以邻近涉及这些主题，但不代表已建立专门的人群任务集。

要解决的问题	适合的验证
疾病或服务需求预测	时间与地区留出；报告预测误差、校准及分层公平性。
干预效果评估	明确对照、目标人群和因果假设；预测相关性不能代替干预效果。
资源分配	模拟或实际受控试点中比较服务覆盖、等待时间和资源成本。

12 数据质量、安全与评测基础设施

实际意义：保证模型分数可以比较、失败可以解释、版本变化可以追踪。它既可成为独立评测方向，也应成为前面十类共同使用的底层协议。

要解决的问题	适合的验证
污染与泄漏	时间留出、相似样本扫描、答案隔离与权限检查。
评分可靠性	正例、反例、等价解、无变化基线与专家一致性；明确错误评分的概率。
可重复执行	固定环境、数据哈希、预算和版本；清理输出后独立重跑。
版本可比性	更改题目或答案后建立新版本，保存可比子集和变更说明。

补充顺序

先把数据质量与评分可靠性做成所有题包的共同门槛，再决定是否扩展公共卫生独立任务。新增类别需要实际任务和来源，不能只补一个分类名称。

价值来自具体决策和可测量收益

六、需求、买方与经济价值

潜在买方	需要决定什么	可交付的评测产品	要验证的收益
模型 / Agent 团队	新版本是否可以发布或替代旧版本	任务集、失败归因、版本回归与预算对照	严重错误减少；同预算成功率提升
药企 / 生物技术团队	候选和分析方案是否进入下一步	私有测量集、候选排序、适用域与校准	固定实验预算下的命中或筛选增益
科研软件 / 计算平台	工具与自动化流程是否可靠	可重跑工作流、工具失败集与兼容性回归	返工减少；完成率和复核时间改善
医院 / 医疗产品团队	本地场景和新模型是否安全适用	本地病例回归、风险分层与专家复核	关键漏报、流程负担和升级人工行为
研究机构 / 挑战社区	方法比较是否公平和可持续	公开协议、版本化数据和盲测	复现性、参与度和方法比较可信度

这是需求假设与产品映射，不能当作已签约客户名单。公开排行榜和论文采用可以证明研究使用，付费意愿需要采购、试点或客户访谈等不同证据。

可以计算的价值

净价值 = 节省的专家与计算成本 + 减少返工的成本 + 可核验的决策收益 - 推理、数据维护、专家复核和部署成本。不同项需要独立测量，避免把时间节省与项目收益重复相加。

试点最先记录：每个合格任务的全成本、专家复核分钟数、严重错误率、干净重跑成功率、固定实验预算下的候选命中率。不要从药物研发或医疗行业总规模直接推导 Benchmark 的市场规模。

> 明确的采用线索
>
> MedBench 的官方平台更新提供累计评测使用信息，可支持“存在重复评测需求”的线索。其统计范围与本目录 45 条样本不同，也未直接披露本报告可核算的评测收入。[R09]

中立评测需要提供内部评测之外的新增价值

七、竞争格局与产品路线

竞争 / 合作层	已有优势	可补的价值	主要难点
模型厂商内部评测	模型访问、版本数据和自身开发资源	跨模型公平协议、外部失败案例及独立审查	客户是否认为外部结论有增量
学术项目与挑战联盟	科学声誉、任务数据与公开协议	工程封装、本地数据迁移和持续维护	必须尊重数据、工具及再分发许可
科研软件和行业平台	工具接入、工作流与实际用户	跨工具对照、科学失败归因和客户验收	已有平台可能自建同类评测
通用数据与评测服务	交付组织和批量数据生产	专业任务设计、参考解和科学验证	质量一致性及专家成本
企业私有评测团队	私有实验和真实失败数据	标准化运行、独立盲审与外部比较	权限、可信交付和客户数据获取

建议的三阶段产品

阶段	具体交付	推进条件
公开研究入口	报告、来源版图、窄域任务样例和可复现结果	能说明评测检验的科学错误；版本与许可可追溯
私有场景试点	客户目标、数据范围、评分与预算协议、失败分析	客户有具体决策；数据获准使用；基线和验收标准明确
持续评测服务	模型更新回归、题集维护、漂移与新失败跟踪	客户重复使用；收益足以覆盖更新和专家复核成本

产品优先级是本报告建议，尚无足够资料对商业竞争强度作精确排序。复购潜力应通过客户在模型、数据或工具更新时是否主动再次使用来验证。

把版图研究转成可检查的评测能力

八、可先启动的两种最小试点

试点 A：单细胞 / 扰动分析的科学验收

项目	建议任务
输入	获准使用的表达数据、细胞与生物重复信息、扰动与对照标签；冻结数据划分和目标估计量。
模型工作	质控、批次与重复诊断、基线比较、效应估计，输出可运行代码和结果解释。
客观评分	效应方向与估计误差、置信区间、预注册负控、未见条件表现；组合任务检验非相加效应。
有效负控	标签置换、无变化或均值基线、只利用批次信息的捷径；确认参考结论在数据中可识别。
完成标准	独立重跑、等价方法可通过、错误方法可被拦下；准确性与执行成本分开报告。

双扰动题可使用 Δint = (AB - C) - (A - C) - (B - C)。若在变换后的表达尺度上计算，必须在公开任务中写清尺度、对照与重复单位。模型不应仅凭总体表达相关性获得成功。

试点 B：可追溯证据检索与更新

项目	建议任务
输入	一组有限且获准使用的论文或来源快照，明确问题、截止时间与可访问资料。
模型工作	检索支持与反对证据，回答限定主张，定位来源并处理无法确认的信息。
评分	主张是否被证据直接支持、引用可定位、反证覆盖、时间约束与弃答质量。
完成标准	专家盲审样例与自动引用检查相符；每条有效证据与复核成本可测量。

任务规模怎么定

先挑能独立核验的小样例，按失败模式覆盖增加数量；达到稳定评分后再做功效或样本量设计。任何演示集的成功率都不能直接外推到完整领域。

建议以 90 天为规划窗口；不是已承诺交付

九、实施路线与验收标准

阶段	具体工作	进入下一阶段的条件
第 1-2 周：来源与协议	核验优先来源、机构角色、版本和许可；明确目标客户决策与主评测单位。	每条重要主张有来源；所需数据能合法使用；选择一个窄域试点。
第 3-4 周：参考与评分	完成参考解、负控、等价解、评分阈值与执行环境；建立干净重跑。	正确方法通过；错误与捷径样例失败；评分分歧可以解释。
第 5-8 周：模型对照	在同一协议与预算下比较若干模型配置，记录成功、成本和失败归因。	指标与版本绑定；结果可重跑；能说明任务对模型的区分来自哪里。
第 9-12 周：场景试点	在获授权的用户场景中验证复核时间、错误率和真实决策增益。	用户认为结果能改变其选择；收益覆盖交付成本；是否继续使用有证据。

正式发布前的共同检查

科学性：目标可识别，基线合理，重复单位正确，统计假设与评分范围一致。公平性：公开任务说明已披露全部评分义务，允许科学等价解。可复现性：数据、工具、版本和预算固定，评分证据来自实际执行。

报告指标应包括分层成功率及不确定性、严重错误率、重跑一致性、人工复核成本与每个有效任务成本。难度和轨迹长度分别报告；长时间运行不是任务价值或科学成功的替代指标。

下一次版图更新应新增什么

建议新增逐主张的来源记录：机构角色、Benchmark 版本、核验状态、采用信号、适用范围、来源时间与访问时间。对 BixBench 合作署名、MedBench 平台采用等差异单独登记，保持历史与新证据的可比较性。

本报告结论

本项目可以发展为生物医药 AI 能力与评测情报入口。第一步应证明一个窄域任务能可靠区分有效和无效方法，第二步验证它是否改变真实用户的选择，再据此扩大数据和服务范围。

官方与作者来源；检索 / 访问截止 2026-10-13

十、参考来源 1/2

[R01] OpenAI：Introducing HealthBench
openai.com/index/healthbench/

[R02] OpenAI：Introducing LifeSciBench
openai.com/index/introducing-life-sci-bench/

[R03] OpenAI：Introducing GeneBench-Pro
openai.com/index/introducing-genebench-pro/

[R04] Anthropic：Evaluating Claude with BioMysteryBench
www.anthropic.com/research/Evaluating-Claude-For-Bioinformatics-With-BioMysteryBench

[R05] Microsoft AI：The Path to Medical Superintelligence / SDBench
microsoft.ai/news/the-path-to-medical-superintelligence/

[R06] Microsoft：HealthAgentBench 官方仓库
github.com/microsoft/HealthAgentBench

[R07] Google Research：Large Language Models Encode Clinical Knowledge
research.google/pubs/large-language-models-encode-clinical-knowledge/

[R08] 清华 / 上海 AI Lab：MedXpertQA 官方项目页
medxpertqa.github.io/

[R09] 上海 AI Lab：MedBench 5.0 更新与采用信号，2026-07-30
www.shlab.org.cn/news/5444287

[R10] FreedomIntelligence：CMB 官方仓库
github.com/FreedomIntelligence/CMB

[R11] BioASQ：The Challenge
bioasq.org/

[R12] FutureHouse：LAB-Bench 官方介绍
www.futurehouse.org/research/lab-bench-measuring-capabilities-of-language-models-for-biology-research

[R13] FutureHouse / ScienceMachine：BixBench 官方仓库及合作署名
github.com/Future-House/BixBench

[R14] BiomniBench 作者：BiomniBench: Process-level Evaluation，预印本
www.biorxiv.org/content/10.64898/2026.05.12.724604v1

R14 本次可核验作者预印本的检索元数据，正文访问受限；过程评测的具体协议未完成全文审查。有关机构合作与评分细节保留待核验，不据此给出效果数值。

官方与作者来源；检索 / 访问截止 2026-10-13

十、参考来源 2/2

[R15] Open Problems：Single-Cell Benchmarks / 官方任务平台
www.openproblems.bio/

[R16] Theis Lab / 合作者：scIB 官方仓库
github.com/theislab/scib

[R17] Stanford SNAP：GEARS 官方仓库
github.com/snap-stanford/GEARS

[R18] ByteDance Research：ProteinBench 官方项目页
proteinbench.github.io/

[R19] ByteDance：PXMeter 官方仓库
github.com/bytedance/PXMeter

[R20] ByteDance：PXDesignBench 官方仓库
github.com/bytedance/PXDesignBench

[R21] OATML-Markslab / 合作者：ProteinGym 官方仓库
github.com/OATML-Markslab/ProteinGym

[R22] Prediction Center：CASP 官方入口
predictioncenter.org/

[R23] CAMEO：Continuous Automated Model EvaluatiOn
cameo3d.org/

[R24] TDC：Leaderboard Guide
tdcommons.ai/benchmark/overview/

[R25] PoseBusters 作者：官方仓库：分子姿态合理性检查
github.com/maabuu/posebusters

[R26] PhysioNet：MIMIC-CXR v2.1.0 数据与访问条件
physionet.org/content/mimic-cxr/2.1.0/

[R27] UniPat AI：PaperBenchX 官方介绍
unipat.ai/blog/PaperBenchX

[R28] ByteDance Seed：SuperGPQA 官方介绍
seed.bytedance.com/en/blog/doubao-seed-team-launched-supergpqa-an-open-source-benchmark-test-set-covering-285-disciplines

仓库数据来源：GroundSignal 生物方向的benchmark调查报告专题；统计基于重命名前 main 提交 ed60c7d 的 CSV 快照。统计来自 benchmark_registry、benchmark_organization、organization_entity、benchmark_subcategory_mapping、benchmark_assessment、benchmark_economic_value_evidence 六张 CSV。

现有登记表中的长尾项目与上述重点核验来源具有不同证据状态。网页或官方介绍可支持项目身份与描述，不能替代合同、临床试验、实验命中或独立复现证据。

报告中的产品路径、潜在用户、试点和 90 天安排为分析建议；未形成对收入、估值、市场规模或执行结果的承诺。